Feature Engineering

Notamos que un problema era usar "datos del futuro" para predecir algo del pasado (data leakage). Para evitarlo nos aseguramos de que si una persona pidió un préstamo en una fecha, solo se mirara su comportamiento bancario anterior a ese día.

Armamos unas 33 variables nuevas. Las más importantes fueron:

- Historial de atrasos: Sacamos promedios, máximos y el porcentaje de veces que la persona se había atrasado más de un mes en el pasado.
- ¿Está empeorando?: Comparamos cómo le fue en los últimos 3 y 6 meses versus su historial total para ver si sus saldos o demoras venían empeorando.
- Ratios lógicos: Armamos fórmulas simples como "Monto del préstamo dividido por su sueldo" o "Sueldo versus saldo promedio en la cuenta". Esto ayudó a ver si la persona estaba pidiendo más de lo que razonablemente podía devolver.

¿Qué probamos y qué descartamos?

Durante el armado fuimos probando distintas cosas para no complicar el modelo sin sentido:

1. **Lo básico**: Entrenamos un modelo solo con los datos de la solicitud (monto, sueldo, tasa). Nos fue bastante mal (ROC-AUC de apenas 0.59).

2. **Usar todo**: Le metimos las 33 variables que armamos y el rendimiento mejoro a casi 0.85 de AUC. Pero era un modelo muy grande y difícil de explicar.

3. **Decisión final**: Para hacer un modelo simple que no se memorice los datos, analizamos qué variables aportaban de verdad. Nos quedamos solamente con las 3 más valiosas: la relación entre el monto y el saldo bancario (monto_vs_saldo), el porcentaje de mora (pct_mora) y el promedio de atrasos (atraso_mean). Con apenas esas 3, el modelo seguía rindiendo bien (AUC de 0.84).

Modelo y Selección de Préstamos

Usamos HistGradientBoostingClassifier porque aprende muy rápido y se lleva muy bien con este tipo de datos. Como necesitábamos usar la probabilidad real de que alguien pague para poder calcular ganancias (y no solo un puntaje suelto), le aplicamos una calibración isotónica.

Para elegir qué préstamos financiar hicimos cuentas simples: multiplicamos la probabilidad de que pague por la tasa de interés que ofrecía. Si la ganancia esperada daba positivo, lo poníamos en nuestra lista. Finalmente, ordenamos a la gente de mayor a menor rentabilidad esperada y fuimos repartiendo el dinero hasta quedarnos sin presupuesto.

Resultados de Negocio (Submission)

Con nuestra estrategia, logramos seleccionar 665 préstamos con esperanza positiva. Invertimos un total de $1.999.600 USD del presupuesto inicial, logrando que nos sobraran apenas $400 USD en la caja.